

Practica 12

Análisis Predictivo de la Calidad del Aire: Aplicación de Modelos de Regresión al Conjunto de Datos Airquality.

Garay Pérez Matthew Ilveneff

202210036@tesco.edu.mx

Tecnológico de Estudios Superiores
de Coacalco

Ingeniería en Sistemas
Computacionales

Programación Lógica Y Funcional

Ing. Vivanco Benavides Luis Enrique

Entrega 19 de mayo de 2025

3721

Introducción


El cambio climático y la contaminación atmosférica representan algunos de los retos más urgentes en la actualidad, debido a sus implicaciones para la salud pública, el medio ambiente y la sostenibilidad urbana (IPCC, 2021). Entre los contaminantes atmosféricos más relevantes se encuentra el ozono troposférico, un gas que, en concentraciones elevadas, puede afectar el sistema respiratorio humano, contribuir a enfermedades cardiovasculares y dañar la vegetación (World Health Organization [WHO], 2021). Por ello, el monitoreo y modelado de su comportamiento a partir de variables meteorológicas es una herramienta clave para los científicos, tomadores de decisiones y autoridades ambientales.

En este estudio se utiliza el conjunto de datos `airquality` del entorno de R, el cual contiene observaciones de calidad del aire en la ciudad de Nueva York durante la primavera y el verano de 1973. Este dataset incluye variables como la concentración de ozono (`Ozone`), radiación solar (`Solar.R`), temperatura (`Temp`), velocidad del viento (`Wind`), mes (`Month`) y día del mes (`Day`) (Chambers, 1992). La disponibilidad de estas variables facilita la construcción de modelos estadísticos que permiten predecir el nivel de ozono a partir de condiciones climáticas.

Para ello, se aplican tres enfoques de regresión: el modelo de regresión lineal simple, que evalúa el efecto de la temperatura sobre el ozono; la regresión lineal múltiple, que incorpora otras variables explicativas como la radiación solar y el viento; y la regresión polinómica, que permite capturar relaciones no lineales entre la temperatura y el ozono. Estos modelos son evaluados mediante métricas como el coeficiente de determinación (R^2), los errores estándar y la significancia estadística de los coeficientes, con el objetivo de identificar cuál modelo se ajusta mejor a los datos observados y tiene mayor capacidad predictiva (James et al., 2013).

Además, la implementación en R permite automatizar el análisis, generar visualizaciones claras a través de la biblioteca `ggplot2`, y aplicar buenas prácticas en ciencia de

datos para asegurar la transparencia y reproducibilidad del estudio (Wickham, 2016). De esta forma, se demuestra cómo la estadística aplicada puede ser una herramienta poderosa para comprender fenómenos ambientales complejos y proponer soluciones basadas en datos.




Desarrollo

1. Explorar el dataset Airquality

En esta práctica estuvimos trabajando con el dataset `airquality`, que es un conjunto de datos integrado en R que contiene información sobre la calidad del aire en Nueva York durante 1973. Primero, cargamos los datos y utilizamos la función `head()` para explorar las primeras filas y familiarizarnos con las variables. Luego, limpiamos el dataset eliminando las filas que contenían valores faltantes (NA), ya que estos pueden afectar negativamente los modelos estadísticos. Guardamos la versión limpia en una nueva variable llamada `aircomplete`, y verificamos sus dimensiones y resumen estadístico para entender mejor su estructura. A partir de ahí, comenzamos a crear varios modelos de regresión lineal utilizando la función `lm()`. El primer modelo fue para predecir el nivel de ozono (Ozone) en función de todas las demás variables, lo cual nos permitió ver qué factores influían más en su concentración. También hicimos modelos similares para otras variables dependientes como la temperatura, el viento, y la radiación solar.

Más adelante, nos enfocamos en un modelo de regresión lineal simple que relaciona directamente la variable de ozono con la temperatura, para observar si existe una relación directa entre el calor y la concentración de ozono. Luego construimos un modelo de regresión

múltiple, esta vez usando el ozono como variable dependiente y como independientes la radiación solar, el viento y la temperatura. Por último, nos metimos en el análisis no lineal mediante una regresión polinómica. Para esto, creamos nuevas variables que representan potencias de la temperatura (al cuadrado, cúbica y cuarta) y construimos un modelo polinómico que permite capturar relaciones más complejas entre la temperatura y el ozono.



The downloaded binary packages are in
C:\Users\matth\AppData\Local\Temp\RtmpXjGox\downloaded_packages

```
> library(ggplot2)
>
> #1.Explorar el dataset
> head(airquality)
  ozone solar.R wind Temp Month Day
1    41    190  7.4  67   5   1
2    36    118  8.0  72   5   2
3    12    149 12.6  74   5   3
4    18    313 11.5  62   5   4
5    NA     NA 14.3  56   5   5
6    28     NA 14.9  66   5   6

> aircomplete <- airquality[complete.cases(airquality), ]
> print(aircomplete)
  ozone solar.R wind Temp Month Day
1    41    190  7.4  67   5   1
2    36    118  8.0  72   5   2
3    12    149 12.6  74   5   3
4    18    313 11.5  62   5   4
7    23    299  8.6  65   5   7
8    19     99 13.8  59   5   8
9     8     19 20.1  61   5   9
12    16    256  9.7  69   5  12
13    11    290  9.2  66   5  13
14    14    274 10.9  68   5  14
15    18     65 13.2  58   5  15

148   14     20 16.6  63    9  25
149   30    193  6.9  70    9  26
151   14    191 14.3  75    9  28
152   18    131  8.0  76    9  29
153   20    223 11.5  68    9  30

>
> cat("Dimensiones del dataset Airquality(Rasurado):", dim(aircomplete), "\n")
Dimensiones del dataset Airquality(Rasurado): 111 6
> summary(aircomplete)
  ozone      solar.R      wind      Temp      Month      Day
Min.   : 1.0   Min.   : 7.0   Min.   : 2.30   Min.   :57.00   Min.   :5.000   Min.   : 1.00
1st Qu.:18.0   1st Qu.:113.5   1st Qu.: 7.40   1st Qu.:71.00   1st Qu.:6.000   1st Qu.: 9.00
Median :31.0   Median :207.0   Median : 9.70   Median :79.00   Median :7.000   Median :16.00
Mean   :42.1   Mean   :184.8   Mean   : 9.94   Mean   :77.79   Mean   :7.216   Mean   :15.95
3rd Qu.:62.0   3rd Qu.:255.5   3rd Qu.:11.50   3rd Qu.:84.50   3rd Qu.:9.000   3rd Qu.:22.50
Max.   :168.0   Max.   :334.0   Max.   :20.70   Max.   :97.00   Max.   :9.000   Max.   :31.00
> |
```

```

Error: objeto 'modelo_tem' no encontrado
> modelo_ozone <- lm(Ozone ~ ., data = aircomplete)
> summary(modelo_ozone)

Call:
lm(formula = ozone ~ ., data = aircomplete)

Residuals:
    Min       1Q   Median       3Q      Max
-37.014 -12.284  -3.302   8.454  95.348

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -64.11632    23.48249  -2.730  0.00742 **
Solar.R      0.05027     0.02342   2.147  0.03411 *
wind        -3.31844     0.64451  -5.149 1.23e-06 ***
Temp         1.89579     0.27389   6.922 3.66e-10 ***
Month       -3.03996     1.51346  -2.009 0.04714 *
Day          0.27388     0.22967   1.192 0.23576
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 20.86 on 105 degrees of freedom
Multiple R-squared:  0.6249,    Adjusted R-squared:  0.6071
F-statistic: 34.99 on 5 and 105 DF,  p-value: < 2.2e-16

>
> modelo_temp <- lm(Temp ~ ., data = aircomplete)
> summary(modelo_temp)

Call:
lm(formula = Temp ~ ., data = aircomplete)

Residuals:
    Min       1Q   Median       3Q      Max
-20.110  -4.048   0.859   4.034  12.840

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  57.251830    4.502218  12.716 < 2e-16 ***
Ozone        0.165275     0.023878   6.922 3.66e-10 ***
Solar.R      0.010818     0.006985   1.549   0.124
wind        -0.174326     0.212292  -0.821   0.413
Month        2.042460     0.409431   4.989 2.42e-06 ***
Day         -0.089187     0.067714  -1.317   0.191
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.159 on 105 degrees of freedom
Multiple R-squared:  0.6013,    Adjusted R-squared:  0.5824
F-statistic: 31.68 on 5 and 105 DF,  p-value: < 2.2e-16

```


2. Generar los gráficos de Regresión Lineal Simple, Multiple y Polinomial



Después de haber construido nuestros modelos de regresión —lineal simple, múltiple y polinómica—, pasamos a la segunda parte del análisis: **generar gráficos** para visualizar los resultados y entender mejor la relación entre la temperatura y el ozono. Usamos la librería `ggplot2`, que es excelente para crear visualizaciones elegantes y personalizables.

Primero, hicimos un **gráfico de regresión lineal simple**. En este gráfico, utilizamos `geom_point()` para mostrar los datos reales (es decir, los puntos medidos de temperatura vs ozono), en color rojo. Luego, usamos `geom_line()` para trazar la línea de predicción generada por nuestro modelo lineal simple `lin_reg`. Esta línea azul representa la relación estimada entre temperatura y ozono según el modelo. El título del gráfico y los ejes también se personalizan con `ggtitle()`, `xlab()` y `ylab()` para hacerlo más claro.

Después, hicimos un gráfico similar, pero esta vez con el **modelo de regresión múltiple** (multi_reg). Aunque la gráfica se sigue centrando en la temperatura (en el eje X), en este modelo la predicción del ozono también depende del viento y la radiación solar. Así que la línea azul que se dibuja con predict() viene del modelo múltiple, que considera varias variables al predecir el ozono, aunque solo graficamos contra temperatura por simplicidad visual.

Por último, hicimos el gráfico más interesante: el de la **regresión polinomial**. Para este, creamos una secuencia de valores de temperatura (x_grid) que va desde el mínimo al máximo de temperatura del dataset, avanzando de 0.1 en 0.1 para que la curva sea suave. Luego, usamos geom_point() igual que antes para mostrar los datos reales, pero al trazar la línea (geom_line()), le pasamos a predict() un data.frame que incluye no solo Temp, sino también Temp^2 , Temp^3 y Temp^4 , porque así lo requiere nuestro modelo polinómico poly_reg. Esto permite que la línea azul represente una **curva** más compleja y flexible que se adapta mejor a las variaciones no lineales entre temperatura y ozono.





3. ¿Determinar el modelo más efectivo y por qué?

Después de construir y graficar nuestros tres modelos (lineal simple, múltiple y polinómico), decidimos analizarlos en más detalle usando la función `summary()` para ver sus métricas estadísticas y luego hacer predicciones concretas con cada uno de ellos, usando los mismos valores para comparar los resultados.

Usamos el modelo lineal simple, donde solo se considera la temperatura como predictor del ozono. El `summary(lin_reg)` nos muestra los coeficientes del modelo (intercepto y pendiente), el valor de R^2 , y el error estándar. Luego, hicimos una predicción del nivel de ozono

suponiendo una temperatura de 75°F. Pero este modelo ignora completamente otras variables importantes como la radiación solar o el viento.

Con el modelo de regresión múltiple, usamos no solo la temperatura, sino también la radiación solar (Solar.R) y el viento (Wind). Al aplicar `summary(multi_reg)`, vemos más coeficientes (uno por cada variable), un R^2 generalmente más alto y un modelo que puede ajustarse mejor a la realidad. La predicción con este modelo considera un día con 190 unidades de radiación solar, viento de 7 mph, y temperatura de 75°F. Esta predicción es más informada, porque considera varias condiciones del entorno.

Finalmente, con el modelo polinómico, tomamos solo la temperatura, pero elevándola a diferentes potencias (al cuadrado, cúbica y a la cuarta). Esto hace que el modelo pueda capturar curvaturas complejas en la relación entre ozono y temperatura. Sin embargo, sigue sin considerar otras variables como el viento o la radiación solar. Es decir, sigue siendo un modelo univariable, aunque con una forma más flexible.

```
> summary(lin_reg)

Call:
lm(formula = Ozone ~ Temp, data = aircomplete)

Residuals:
    Min       1Q   Median       3Q      Max
-40.922 -17.459  -0.874  10.444 118.078

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -147.6461    18.7553  -7.872 2.76e-12 ***
Temp         2.4391     0.2393   10.192 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 23.92 on 109 degrees of freedom
Multiple R-squared:  0.488,    Adjusted R-squared:  0.4833
F-statistic: 103.9 on 1 and 109 DF,  p-value: < 2.2e-16

> predict(lin_reg, data.frame(Temp = 75))
      1
35.28717
>
> summary(multi_reg)

Call:
lm(formula = Ozone ~ Solar.R + Wind + Temp, data = airquality)

Residuals:
    Min       1Q   Median       3Q      Max
-40.485 -14.219  -3.551   10.097   95.619

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -64.34208    23.05472  -2.791  0.00623 **
Solar.R      0.05982     0.02319   2.580  0.01124 *
Wind        -3.33359     0.65441  -5.094 1.52e-06 ***
Temp         1.65209     0.25353   6.516 2.42e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 21.18 on 107 degrees of freedom
(42 observations deleted due to missingness)
Multiple R-squared:  0.6059,    Adjusted R-squared:  0.5948
F-statistic: 54.83 on 3 and 107 DF,  p-value: < 2.2e-16

> predict(multi_reg, data.frame(Solar.R = 190, Wind = 7.0, Temp = 75))
      1
47.59566
>
> summary(poly_reg)

Call:
lm(formula = Ozone ~ Temp + Temp2 + Temp3 + Temp4, data = aircomplete)

Residuals:
    Min       1Q   Median       3Q      Max
-34.344 -10.655  -2.386   5.914 124.656

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.469e-04    6.389e-03  -2.298  0.0235 *
Temp         8.053e-02    3.401e-02   2.368  0.0197 *
Temp2       -1.637e-01    6.735e-03  -2.431  0.0167 *
Temp3        1.462e-01    5.881e-02   2.486  0.0145 *
Temp4       -4.828e-04    1.911e-04  -2.526  0.0130 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 22.14 on 106 degrees of freedom
Multiple R-squared:  0.5736,    Adjusted R-squared:  0.5575
F-statistic: 35.65 on 4 and 106 DF,  p-value: < 2.2e-16

> predict(poly_reg, data.frame(Temp = 75, Temp2 = 75^2, Temp3 = 75^3, Temp4 = 75^4))
      1
23.11614
> |
```

¿Por qué el modelo de regresión múltiple es más efectivo? *Considera múltiples factores climáticos reales*

A diferencia de los otros dos modelos, el modelo múltiple toma en cuenta temperatura, viento y radiación solar, lo cual se ajusta mejor a la realidad, ya que el ozono en el ambiente no depende solo del calor, sino de una combinación de variables atmosféricas.

Predicción más precisa y realista

El modelo múltiple permite hacer predicciones que reflejan condiciones específicas, como un día soleado, pero con poco viento. Esto lo vuelve más útil para estudios ambientales, políticas públicas o incluso alertas de calidad del aire.

Conclusiones

El presente análisis permitió evaluar la relación entre la concentración de ozono y distintas variables meteorológicas utilizando modelos de regresión lineal simple, múltiple y polinómica. A partir de los resultados obtenidos, se concluye que el modelo de regresión lineal múltiple ofrece una mejor capacidad predictiva, como lo demuestra su mayor coeficiente de determinación (R^2), en comparación con los modelos simple y polinómico. Esto se debe a que incorpora múltiples variables independientes relevantes (radiación solar, viento y temperatura), lo que le permite capturar mejor la complejidad del fenómeno atmosférico en estudio.

La regresión lineal simple, aunque útil para ilustrar la relación directa entre temperatura y ozono, resultó limitada al ignorar otros factores meteorológicos que también influyen en la formación del ozono troposférico. Por su parte, el modelo polinómico mostró un ajuste más flexible a los datos, pero su complejidad incrementada no necesariamente implicó una mejora significativa en la capacidad explicativa del modelo frente al modelo múltiple, lo que puede deberse al sobreajuste o a la colinealidad entre términos polinómicos.

Desde una perspectiva práctica, este ejercicio demuestra el valor de la estadística aplicada y del software R para el análisis exploratorio de datos ambientales, facilitando la construcción de modelos predictivos basados en evidencia empírica. Asimismo, resalta la importancia de considerar múltiples variables en el estudio de fenómenos ambientales, lo cual es esencial para tomar decisiones más informadas en materia de salud pública, urbanismo y gestión de la calidad del aire.

Finalmente, este estudio confirma que el uso de técnicas de ciencia de datos en conjunto con bases de datos históricas puede contribuir significativamente a la comprensión y predicción de problemáticas ambientales, promoviendo una toma de decisiones más eficiente y fundamentada en datos reales.

Referencias Bibliográficas

Chambers, J. M. (1992). Data for air quality measurements in New York, 1973. Base de datos airquality, disponible en R base.

Intergovernmental Panel on Climate Change. (2021). Climate Change 2021: The Physical Science Basis. Cambridge University Press. <https://www.ipcc.ch/report/ar6/wg1/>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning: With Applications in R. Springer.

Wickham, H. (2016). ggplot2: Elegant graphics for data analysis. Springer.

World Health Organization. (2021). WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. <https://www.who.int/publications/i/item/9789240034228>